

Hi-EM 실험 가이드

scripts/experiment.py 사용법 + 결과 해석 요약. 더 깊은 알고리즘 정의는 context/methodology/README.md .

1. scripts/experiment.py 가 만드는 출력물

새 sweep / ablation / comparison 은 scripts/experiment.py 한 entry 로 돌린다 (Claude Code 에 “이런 method 들로 돌려줘” 라고 부탁). 이 스크립트가 method × HP 조합마다 자식 프로세스 (run_experiment.py) 를 띄우고, 끝나면 결과를 모아 REPORT.md 한 장으로 만든다.

전체 산출물은 outputs/experiments/<name>/ 안에 self-contained 로 모인다:

```
outputs/experiments/<name>/
├── REPORT.md                                ← (1) 전체 비교 표 ★ committed
├── <label>/
│   ├── exit_code.txt                       ← method × HP 1 조합 마다 한 폴더
│   ├── run.log                             ← (2) 자식 종료 코드 ("0"=성공, resume key)
│   ├── stm_topk.json                       ← (3) 자식 stdout (디버그용)
│   └── results/experiments/<exp_id>/
│       ├── summary.json                   ← (4) STM 통계 (hi-em-full-* 만)
│       └── rounds/round_NNN/
│           ├── hypothesis.jsonl           ← (5) 이 method 의 전체 metric (REPORT 의 한 행 원본)
│           └── judged.jsonl              ← 질문 200 개씩 한 round
│                                           ← (6) LLM 답변 raw
│                                           ← (7) judge 결과 + per-Q metric
```

각 파일의 의미:

- REPORT.md** — 모든 method 끝나면 자동 생성. 각 row 의 metric 은 (5) summary.json + (4) stm_topk.json 에서 뽑아온 값. 이 파일만 커밋, 나머지 raw 는 모두 .gitignore . 이미 끝난 sweep 의 표만 다시 그리고 싶으면 Claude Code 에 “aggregate-only 로 다시 만들어줘” 하면 됨.
- exit_code.txt** — 0 이면 그 method 완료. 같은 <name> 으로 재실행하면 0 인 method 는 skip → 중간에 죽어도 안전하게 이어 돌림.
- run.log** — 자식 프로세스 stdout. 실험이 죽거나 이상하면 여기 본다.
- stm_topk.json** — hi-em-full-* method 만. round 마다 STM 안의 가장 큰 topic 1·2·3 의 turn 수를 push. REPORT 의 STM 컬럼 (T1μ 등) 원본.
- summary.json** — 그 method 의 전체 metric (정확도 + qtype 별 + 평균 latency + retrieval). REPORT 의 한 행 원본.
- hypothesis.jsonl** — 질문 1 개당 한 줄, LLM 답변 + 메타데이터 (어떤 turn 들을 retrieved 했는지 등). 답변 자체를 보고 싶을 때.
- judged.jsonl** — hypothesis.jsonl 에 judge LLM 의 yes/no 평가 + per-question retrieval metric (H@k / R@k / P@k) 를 붙인 것. 잘 못 맞춘 질문 case 분석할 때.

참고 — 다른 outputs/ 디렉토리:

```
outputs/
├── experiments/    ← 위 트리 (sweep 들의 본진)
├── runs/           ← run_experiment.py 단독 호출 (디버그/smoke). gitignored.
├── reports/        ← 사람이 쓴 독립 분석 MD. committed.
└── design/         ← 설계 문서. committed.
```

archive/ 는 의도적으로 폐기한 실험 (README.md 에 폐기 사유 기록). 실험 데이터는 모두 gitignored.

2. REPORT.md 표 — 컬럼 설명

REPORT.md 의 행 = method × HP 1 조합. 컬럼은 4 그룹:

(a) 정확도 (LLM judge yes/no, 0~1)

컬럼	의미
accuracy_overall	전체 평균 정확도
multi-hop	여러 turn 의 정보를 합쳐야 답하는 질문 (cat 1)
single-hop	한 turn 만 보면 되는 질문 (cat 4)
temporal-reasoning	시간 추론 질문 (cat 2)
adversarial	“Not mentioned in conversation” 류 (cat 5, multi-choice)
open-domain	자유 답변 질문 (cat 3)

(b) latency / 비용

컬럼	의미
gen_p50(s)	per-question LLM generation 시간 (중앙값)
wall	method 전체 wall-clock time

(c) STM 통계 (hi-em-full-* 만)

stm_topk.json 에서 매 round 마다 STM 안에서 가장 큰 topic 1·2·3 의 turn 수를 기록.

컬럼	의미
T1μ / T2μ / T3μ	round 평균 — STM 1·2·3위 topic 의 turn 수
T1max / T2max	전 round 중 1·2위 topic 최대 turn 수 (mega-topic 진단)
T1var	round 간 1위 topic 크기 변동
STM_n_topics	round 평균 STM 안 topic 개수

→ 진단 활용: T1μ 가 100+ 면 mega-topic 의심, STM_n_topics 가 1 이면 single-topic 으로 collapse.

(d) Retrieval (정답 turn 회수율, LoCoMo evidence 기준)

LoCoMo 는 질문마다 정답이 들어있는 turn 의 dia_id 리스트 (evidence) 를 제공. method 가 LLM 에 prefill 한 turn 의 dia_id 와 비교.

k = method 가 LLM 에 prefill 한 turn 수 (method 마다 다름):

method	k
hi-em-full-*	STM 안 모든 turn ($\approx 100-200$)
rag / rag-summary / rag-observation	rag_k = 10
sliding	sliding_k = 20
full	전체 history

컬럼	의미
H@k	Hit@k — prefill 안에 정답 turn 이 1개 이상 있는 비율
R@k	Recall@k — 정답 turn 들 중 몇 % 가 prefill 에 있는가
R-multi-hop@k	multi-hop 질문만 따로 본 R@k (모든 evidence 가 들어가야 답 가능)
P@k	Precision@k — prefill 중 정답 비율 (낮으면 noise 多)

→ 진단 활용: hi-em 의 P@k 가 RAG 의 1/22 (0.003 vs 0.07) — k 가 hi-em 은 ~ 150 , RAG 는 10 이라 noise 차이 큼. topic 단위 prefill 의 본질적 한계를 보여주는 지표. acc bottleneck 진단의 핵심.

3. methodology 디렉토리 안내

알고리즘 정의는 모두 `context/methodology/` 에 모여 있다.

`context/methodology/`

— README.md	← ★ 먼저 보는 곳. 버전 계보 + 한 줄 요약 + HP 매트릭스
— infrastructure.md	← 버전 무관 인프라 (cache, encoder lock, REPORT 컬럼 정의 등)
— v1.md	← Gaussian likelihood baseline
— v2.md	← v1 + STM round-clear / sessioned preload
— v3.1.1.md	← Gaussian → bounded cosine
— v3.2.1.md	← sticky-CRP count 에 sub-linear $(C+1)^\beta$
— v3.3.1.md	← centroid → per-topic GRU 예측
— v3.3.2.md	← + SEM2 surprise hard PE boundary
— v3.3.3.md	← + SEM2 f0 / restart 분기 복원
— v3.3.4.md	← hard PE → per-topic σ^2_k calibrated likelihood

언제 어디를 보는가:

- 새 sweep 돌릴 때 어떤 method 가 무슨 HP 를 쓰는지 알고 싶다 → `README.md` 의 HP 매트릭스 한 표.
- 특정 버전의 식 / SEM 계승 / 알려진 한계 / 최근 sweep 결과를 보고 싶다 → 해당 `vX.Y.Z.md`.
- 캐시 / encoder lock / 새 버전 추가 절차 등 인프라 질문 → `infrastructure.md`.