

Hi-EM Methodology — version index

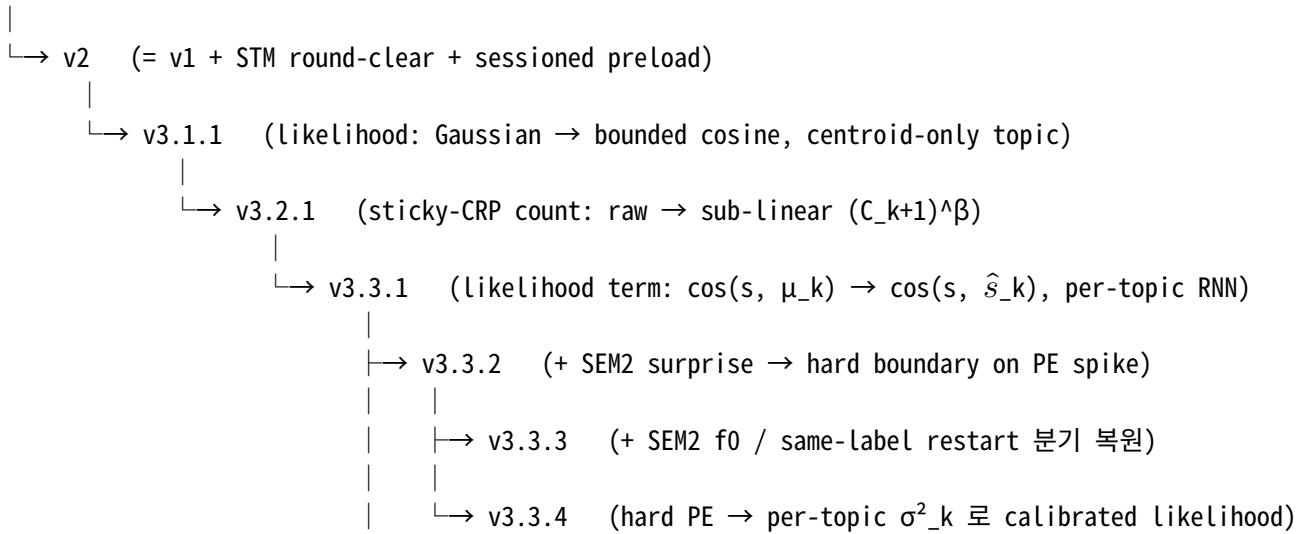
이 파일 위치: `context/methodology/README.md`

이 디렉토리 (`context/methodology/`) 의 역할:

- 각 버전 (v1, v2, v3.1.1, ..., v3.3.4) 의 **알고리즘 수준 차이**를 한 파일씩 정리.
- 사소한 변경 (prediction caching, hyperparameter default, prior decay 등) 도 해당 버전 파일의 “고려 중인 변형” / “변경 이력” 섹션에 누적.
- 코드 위치 / 인프라 (cache, encoder lock, REPORT 컬럼 정의) 는 같은 디렉토리의 `infrastructure.md` 별도.

버전 계보

v1 (Gaussian likelihood, flat history)



한 줄 요약

버전	segmenter class	핵심 차이
v1	HiEMSegmenter	SEM2 본진 — Gaussian likelihood + raw sticky-CRP
v2	HiEMSegmenter	v1 segmenter 그대로 + STM round-clear / session-aware preload
v3.1.1	HiEMSegmenterV3	Gaussian → bounded cosine $\tau \cdot \cos(s, \mu_k)$
v3.2.1	HiEMSegmenterV32	sticky-CRP count 식에 sub-linear $(C_{k+1})^\beta$
v3.3.1	HiEMSegmenterV331	μ_k 대신 per-topic GRU 예측 $\hat{s}_k$ 로 cos 점수
v3.3.2	HiEMSegmenterV332	+ $\max_k \cos < 1 - \text{pe_threshold}$ 면 새 topic 강제 (SEM2 surprise)

버전	segmenter class	핵심 차이
v3.3.3	HiEMSegmenterV333	+ 같은 label 의 repeat / restart 분기 (log_likelihood_f0 복원)
v3.3.4	HiEMSegmenterV334	hard PE rule 제거, likelihood 를 $-PE^2/(2\sigma_k^2)$ 로 calibrate

버전별 hyperparameter 요약 (current LoCoMo sweep value)

표 보는 법:

- 셀 값 = **2026-05-09 LoCoMo full sweep 에서 사용한 값** (= 가장 최근 best HP).
- ★ = 해당 버전의 코드 default 와 다른 값 (= sweep 으로 튜닝됨).
- ★ 없음 = 셀 값이 코드 default 와 동일.
- — = 해당 버전이 그 HP 를 사용하지 않음.

그리스/ASCII 표기 규약 (한 번만 적음):

- α = alpha , λ = lmda , cos = cos_threshold , β = beta , σ_0^2 = sigma0_sq

코드 default 위치 (src/hi_em/sem_core_v*.py 의 __init__):

- v1 / v3.1.1 / v3.2.1 / v3.3.1 / v3.3.2 → alpha=1 , cos=0.7 , beta=0.5 , pe_threshold=1.0 , rnn_train_steps=1
- v3.3.3 / v3.3.4 → alpha=100 , cos=0.9 , beta=0.25 , pe_threshold=0.5 , rnn_train_steps=3 (codex 가 v3.3.2 best HP 를 default 로 박음)

표에서 생략된 HP:

- RNN 보조 (모든 v3.3.x 공통): rnn_hidden_dim=32 , rnn_lr=1e-3 , rnn_max_context=8 , rnn_min_history=2
- 자세히는 해당 버전의 vX.Y.Z.md 참조.

HP	v1	v3.1.1	v3.2.1	v3.3.1	v3.3.2	v3.3.3	v3.3.4
α (alpha)	1	10★	100★	100★	100★	100	100
λ (lmda)	10	10	10	10	10	10	10
σ_0^2 (sigma0_sq)	0.01	—	—	—	—	—	—
τ (tau)	—	50	50	50	50	50	50
cos (cos_threshold)	—	0.3★	0.9★	0.9★	0.9★	0.9	0.9
β (beta)	—	—	0.25★	0.25★	0.25★	0.25	0.25
pe_threshold	—	—	—	—	0.5★	0.5	(unused unless hard_pe_fallback=True)
rnn_train_steps	—	—	—	1	3★	3	3
restart_pe_threshold	—	—	—	—	—	0.5	—

HP	v1	v3.1.1	v3.2.1	v3.3.1	v3.3.2	v3.3.3	v3.3.4
restart_margin	—	—	—	—	—	0.0	—
f0_tau	—	—	—	—	—	$=\tau$	—
f0_min_starts	—	—	—	—	—	2	—
pe_var_decay	—	—	—	—	—	—	0.95
pe_var_min_samples	—	—	—	—	—	—	5
pe_var_sigma0_sq	—	—	—	—	—	—	0.04
pe_var_min_sq	—	—	—	—	—	—	1e-4
pe_var_max_sq	—	—	—	—	—	—	0.25
var_likelihood_weight	—	—	—	—	—	—	1.0
hard_pe_fallback	—	—	—	—	—	—	False

memory_window HP (모든 hi-em-full 버전 공통):

HP	default
k_topics	3
k_turns_per_topic	5
stm_max_topics	10
stm_max_turns	200
promotion_threshold	0.5
round_size	10

Cross-cutting infrastructure

버전 무관한 인프라 / 설계 결정은 [infrastructure.md](#) 별도. 다음 항목 정리:

- EncoderCache (RAG 임베딩 cache)
- HiEMConvCache (Hi-EM per-conversation state cache)
- encoder lock / `--no-thinking` 플래그
- retrieval policy / STM atomicity
- 새 버전 추가 체크리스트 (코드 측면)
- REPORT.md 컬럼 정의

표기 규약

- s : 새로 들어온 turn의 L2-normalized embedding (768-D)
- μ_k : topic k 의 centroid

- $\hat{s}_k$: topic k의 예측된 다음 embedding (v3.3.1+에서만 의미 있음)
- C_k : topic k의 누적 assignment 수
- $e_{\{n-1\}}$: 직전 turn의 topic id
- α (alpha) : sCRP 새 cluster prior weight
- λ (lmda) : sCRP stickiness
- τ (tau) : cosine likelihood temperature (v3.x)
- β (beta) : sub-linear count exponent (v3.2+)
- σ_0^2 (sigma0_sq) : Gaussian cold-start 분산 (v1/v2 only)
- σ_k^2 (pe_var) : v3.3.4 의 per-topic PE EMA variance

작성 규칙

새 버전 추가 시 — 문서 측면:

- `vX.Y.Z.md` 신규 작성 (직전 버전 파일을 템플릿으로).
- 이 README 갱신:
 - 계보 그림에 entry 추가
 - 한 줄 요약 표에 row 추가
 - HP 매트릭스에 column 추가
- `context/06-decision-log.md` 에 채택/폐기 사유 + 날짜 append.

새 버전 추가 시 — 코드 측면 (자세히는 [infrastructure.md § 7](#) “새 hi-em-full-vX.Y.Z 버전 추가 체크리스트”):

- `src/hi_em/sem_core_vXYZ_*.py` 신규 + topic 클래스 (필요시).
- `src/hi_em/orchestrator.py` 에 `version == "vX.Y.Z"` elif 분기.
- `scripts/run_experiment.py` 세 곳 갱신:
 - `argparse --method choices`
 - `HiEMConvCache._build` HP 매핑
 - 질문 dispatch 의 `seg_version`
- 자동 적용 (별도 set 갱신 불필요): `is_hi_em_method()` regex helper 가 prefix 매칭 → `hiem_cache` / encoder / STM topk 자동 활성화.
- `tests/test_vXYZ_*.py` 단위 테스트.

기존 버전에 마이크로 변경 적용 시:

- 해당 `vX.Y.Z.md` 의 “변경 이력” 섹션에 추가 (날짜 + 한 줄).
- 알고리즘 의미가 바뀌면 새 버전 파일로 분리.
- 단순 성능 / 캐시 최적화는 같은 파일 안에 누적.