

목차

v4.1.1 알고리즘 워크스루 (처음 보는 사람용)	1
0. 이 시스템이 푸는 문제	1
1. 가장 단순한 신호 — δ_{prev}	1
2. 노이즈 평활 — δ_{ctx} (v4.1.1 이 새로 추가)	2
3. 돌을 섞기 — δ_{adj}	2
4. RNN 자리 — δ_{eff} (default 예선 그냥 통과)	2
5. $\delta \rightarrow$ “확률 점수”: likelihood	2
6. 경계 판정이 한 줄로 환원되는 트릭	3
7. 한눈 요약	4
HP default	4
결과 (공식 SuperDialseg metric, $\text{Score}=0.5F1+0.25(1-Pk)+0.25(1-WD)$)	4
한계 / 검증 미해결	4
검증 노트 (2026-05-19, 코드 1:1 대조)	5

v4.1.1 알고리즘 워크스루 (처음 보는 사람용)

src/hi_em/sem_core_v411.py (구 v3.3.10) · 정리 2026-05-19

목적: methodology context/methodology/v4.1.1.md 의 압축된 수식을, SEM/segmentation 을 처음 보는 사람도 따라올 수 있게 “왜 이 식이 나왔는지”까지 풀어 쓴 보조 문서. **코드와 1:1 대조 검증 완료** (검증 노트는 문서 끝 참조). 알고리즘 정의의 단일 진실 원천은 여전히 methodology 파일 — 본 문서는 그 해설판.

0. 이 시스템이 푸는 문제

대화가 turn 단위로 흐른다. 각 turn 발화를 임베딩(문장 벡터) s_t 로 변환해 둔다. 매 turn 결정할 것은 하나: “이 발화는 직전과 같은 주제인가, 새 주제가 시작된 경계(boundary)인가?”

두 벡터의 “비슷함”은 **cosine 유사도** $\cos(a, b)$ 로 잰다(같은 방향 1, 무관 0). 따라서

$$\delta = 1 - \cos(a, b)$$

는 “두 발화가 얼마나 **다른가**” = **놀람의 크기(prediction error, PE)**. $\delta=0$ 직전과 판박이, $\delta \rightarrow 1$ 완전히 딴 얘기. 모든 식은 이 δ 한 개를 더 똑똑하게 만드는 과정이다.

1. 가장 단순한 신호 — δ_{prev}

$$\delta_{\text{prev}}(t) = 1 - \cos(s_{\{t-1\}}, s_t)$$

직전 발화 $s_{\{t-1\}}$ 와 지금 발화 s_t 만 비교. “방금 한 말과 지금 말이 다르면 주제가 바뀐 것.”

왜 SEM 인가: SEM 은 “다음 발화를 예측하는 모델 f 의 예측이 빗나간 정도(PE)가 크면 새 event” 라는 이론이다. f 의 가장 단순한 형태가 “**다음도 직전과 같을 것(identity dynamics)** — 그 예측의 빗나감이 정확히 $1 - \cos(s_{\{t-1\}}, s_t)$. 즉 δ_{prev} 는 임시 휴리스틱이 아니라 SEM 의 cold-start f 그 자체.

코드: `_delta_prev` ([sem_core_v411.py:392](#)). 첫 turn(직전 없음)엔 None.

문제점: 같은 주제 안에서도 잡담하며 말투·소재가 turn 마다 흔들린다 $\rightarrow$ 같은 주제인데 δ_{prev} 가 튀어 **없는 경계를 만든다 (FP 과분할)**. TIAGE 에서 이게 지배적 오류 (FP 393 vs FN 117) $\rightarrow$ v4.1.1 의 동기.

2. 노이즈 평할 — δ_{ctx} (v4.1.1 이 새로 추가)

직전 한 발화 만 보면 그 한 발화가 어쩌다 튀었을 때 속는다. 그래서 **직전 몇 개 발화의 평균적 분위기**와 비교한다.

```
c_{t-1} = normalize( \sum_{i=1..m} p^{i-1} \cdot s_{t-i} )
\delta_{ctx}(t) = 1 - \cos(c_{t-1}, s_t)
```

읽는 법: $-s_{t-1}, \dots, s_{t-m}$: 과거 m 개 발화 (default $m = ctx_window = 3$). **과거만 — 미래는 안 봄(causal)**. online 처리라 아직 안 온 발화는 모른다. $-p^{i-1}$: 가중치. $p = ctx_decay = 0.7$ 이면 직전($i=1$) $p^0=1$, 그 전($i=2$) 0.7 , 그 전($i=3$) $0.49 \dots$ **최근일수록 비중 ↑** 의 기하감쇠. $-\sum \dots$: 가중합 = “최근 맥락을 요약한 한 개의 context 벡터”. $-normalize(\dots)$: 길이 1 로 (cosine 비교용, 방향만 의미). $-\delta_{ctx}$: 그 맥락 벡터와 지금 발화의 거리.

직관: 한 발화가 어쩌다 튀어도, 최근 3개를 섞은 c_{t-1} 은 그 흔들림이 평균에 묻혀 둔해진다 → **같은 주제 안의 잡담성 틈에 덜 속는다.**

코드: `_delta_ctx` ([sem_core_v411.py:404](#)). `reversed(win)` 순회로 `win[-1]=s_{t-1}` 에 p^0 , `win[-2]=s_{t-2}` 에 $p^1 \dots$ 식과 일치. 호출 시점이 `_recent.append(s)` 이전이라 `_recent` 는 과거만 담고 있음(causal 보장). 과거 발화가 아직 없으면 `None`.

3. 둘을 섞기 — δ_{adj}

δ_{prev} (예민, 진짜 경계 안 놓침)와 δ_{ctx} (둔감, 잡담에 안 속음)는 trade-off → **가중 평균**.

```
\delta_{adj} = a \cdot \delta_{prev} + (1-a) \cdot \delta_{ctx} \quad (a = ctx\_blend\_a, \text{ default } 0.5)
```

- $a=1$ 이면 $\delta_{adj} = \delta_{prev} \rightarrow$ **v3.3.9 와 완전 동일**. 즉 v4.1.1 은 v3.3.9 의 일반화이고, a 를 0.5 로 내려 맥락 신호를 절반 섞은 게 개선의 정체.
- δ_{ctx} 가 `None`(과거 없음)이면 $\delta_{adj} = \delta_{prev}$ 로 fallback.
- **a, m, p 는 코퍼스마다 train 셋에서 재추정해야 한다** (test 로 맞추면 leakage). TIAGE-train 재추정값: $m=2, p=0.7, a=0.5, \delta^*=0.5594$.

코드: [sem_core_v411.py:437](#).

4. RNN 자리 — δ_{eff} (default 에션 그냥 통과)

```
\delta_{eff}^2 = \eta \cdot \delta_{adj}^2 + (1-\eta) \cdot \delta_{model}^2 \quad (\eta = eta\_prev, \text{ default } 1.0)
```

δ_{model} = 학습형 RNN(TopicV336)의 PE. η 는 둘의 비중. **default $\eta=1 \rightarrow (1-\eta)=0 \rightarrow \delta_{model}$ 항 소멸 $\rightarrow \delta_{eff} = \delta_{adj}$** . 코드는 이때 GRU forward 자체를 skip (`_uses_rnn() = use_rnn` and `eta_prev < 1.0` 이 `False`).

왜 RNN off: η -ablation(2026-05-18)에서 $\eta < 1$ (RNN 섞기)이 전부 단조 악화. v3.3.x 는 “RNN scene-dynamics 복원” 라인이었는데 그게 무용으로 판명돼 identity 로 돌아선 게 메이저 분리(v4.x)의 이유. 식·코드는 `use_rnn` 플래그로 **보존**(제거 아님).

² 로 묶었다 $\sqrt{}$ 하는 이유: δ 가 다음 단계 가우시안 likelihood 의 “오차”로 들어가므로, 분산을 더하듯 제곱 가중합 후 복원.

코드: `_delta_eff` ([sem_core_v411.py:426](#)). stream 시작($\delta_{prev}=\text{None}$)엔 RNN 안 쓰면 $\delta=0$ fallback.

5. $\delta \rightarrow$ “확률 점수”: likelihood

경계 여부는 점수 비교로 정한다. δ 를 가우시안 log-likelihood 로:

```
L\delta(\delta) = w \cdot ( - \delta^2 / (2 \cdot \sigma\delta^2) ) \quad (w = var\_likelihood\_weight, \text{ default } 1.0)
```

- δ (놀람) 작을수록 $L\delta \rightarrow 0$ (그 주제로 잘 설명됨, 높은 점수); δ 클수록 큰 음수 (설명 안 됨, 낮은 점수).
- $\sigma\delta^2 = \text{“}\delta \text{가 그만큼 흔들리는 건 정상”의 허용 폭(softness). 데이터 추정 아님 — } \sigma\delta^2 = c \cdot \delta^{*2} \text{로 고정 (} c = \text{sigma_delta_c} = 0.0625 = 1/16\text{). online 추정하면 경계에서의 큰 점프까지 분산에 섞여 변별력이 씻겨 over-merge 됐기 때문 (codex 2026-05-18).}$
- w 는 default 1.0 이라 보통 무시 가능하나 식엔 존재.

코드: `_delta_loglik` ([sem_core_v411.py:368](#)), $\sigma\delta^2$ 설정 ([sem_core_v411.py:260](#)).

6. 경계 판정이 한 줄로 환원되는 트릭

매 turn 두 후보의 총점(= log prior + log-likelihood)을 비교한다.

- **이어가기(repeat, $k=\text{prev_k}$)** 총점 = $\log \text{prior_prev} + L\delta(\delta_{\text{eff}})$
- **새 주제(fresh)** 총점 = $\log \text{prior_new} + B0_t$, 여기서 $B0_t = L\delta(\delta^*) + \log(\text{prior_prev} / \text{prior_new})$

fresh 총점 전개:

```
log prior_new + [ Lδ(δ*) + log(prior_prev/prior_new) ]
= log prior_new + Lδ(δ*) + log prior_prev - log prior_new
= log prior_prev + Lδ(δ*)
```

→ 두 총점에서 $\text{prior}(\log \text{항})$ 가 **정확히 상쇄**. 비교가 깔끔히 환원:

- **이어간다** $\Leftrightarrow L\delta(\delta_{\text{eff}}) > L\delta(\delta^*) \Leftrightarrow \delta_{\text{eff}}^2 < \delta^{*2} \Leftrightarrow \delta_{\text{eff}} < \delta^*$
- **경계다** $\Leftrightarrow \delta_{\text{eff}} \geq \delta^*$
- $\delta^* = \text{학습된 임계값}$ — “이 코퍼스/인코더에서 놀람이 이 정도 넘으면 주제 변경”의 컷. 코드 default **0.5557** 은 **v3.3.9 prev-cos placeholder**; v4.1.1 causal config($m=2, p=0.7, a=0.5$) 재calibration 값은 **0.5594**. 코퍼스·인코더·(m, p, a) 바뀌면 train 에서 재추정 필수 (test leakage 금지).
- prior 를 일부러 상쇄하도록 $B0_t$ 를 설계한 이유: sticky-CRP stickiness λ 탓에 시간이 갈수록 prior_prev 가 커져 옛 버전이 “무조건 이어가기”로 쏠려 over-merge 하던 버그를, 매 turn 정확히 $\delta_{\text{eff}} < \delta^*$ 로 고정해 제거하기 위함.
- 단, fresh 슬롯이 이 prior-corrected $B0_t$ 를 쓰는 건 prev_k 가 존재하고 $\text{prior}[\text{prev_k}] > 0$ 일 때. stream 맨 처음(prev_k 없음)엔 $\text{prior-free_l0}() = L\delta(\delta^*)$ ($r0=1$) 로 fallback.

코드: `fresh baseline_fresh_baseline_for_prev` ([sem_core_v411.py:380](#)), 점수 분기 `_scores` ([sem_core_v411.py:498](#)).

결가지: 다른 두 경로

- **restart ($k=\text{prev_k}$ 이지만 trained 이고 $\delta_{\text{eff}} > \text{restart_pe_threshold}=0.5$):** 같은 라벨이라도 “그 주제의 재시작” 으로 보고 stickiness λ 뺀 $\text{prior} + f0 \text{ likelihood}$ 로 채점. repeat vs restart 중 max 채택, restart 이기면 경계.
- **$k \neq \text{prev_k}$ (다른 기존 topic 재진입):** within-event repeat predictor 가 아니라 SEM2 `log_likelihood_f0` — “이 발화가 topic k 의 시작처럼 보이냐”. $f0$ 는 그 topic 의 episode-start centroid (importance-free, retrieval-rule clean) 로만 계산.

이 두 경로의 likelihood scale 은 δ -scale 고정 $\sigma\delta^2$ 가 아니라 SEM2 `map_variance posterior mode` $\sigma^2 = (v_0 \cdot \text{var}_0 + n \cdot v) / (v_0 + n + 2)$ ($n < 2$ 면 prior mode) 를 쓴다 — δ -scale 과 PE-scale 두 likelihood 가 공존 (`_sigma_sq_for` [sem_core_v411.py:333](#)).

최종 boundary = `is_label_change or is_restart` ([sem_core_v411.py:596](#)).

7. 한눈 요약

기호	정의	한 줄
s_t	발화 임베딩	turn 의 문장 벡터
δ_{prev}	$1 - \cos(s_{t-1}, s_t)$	가장 단순한 놀람, 답답에 잘 속음
c_{t-1}	$\text{normalize}(\sum \rho^{i-1} s_{t-i})$	최근 m개 가중합 = “최근 분위기”
δ_{ctx}	$1 - \cos(c_{t-1}, s_t)$	노이즈에 둔한 놀람
δ_{adj}	$a \cdot \delta_{prev} + (1-a) \cdot \delta_{ctx}$	둘을 섞은 놀람 (v4.1.1 핵심)
δ_{eff}	$\sqrt{(\eta \cdot \delta_{adj}^2 + (1-\eta) \cdot \delta_{model}^2)}$	default= δ_{adj} ($\eta=1$, RNN off)
$L\delta$	$w \cdot (-\delta^2 / 2\sigma\delta^2), \sigma\delta^2 = c \cdot \delta^{*2}$ 고정	놀람 $\rightarrow$ 점수 (작을수록 높음)
$B0_t$	$L\delta(\delta^*) + \log(\text{prior}_{prev} / \text{prior}_{new})$	prior 상쇄용 fresh baseline
δ^*	학습된 컷 (train 추정)	$\delta_{eff} \geq \delta^*$ 이면 경계

핵심 한 줄: **v4.1.1 = v3.3.9(δ_{prev} only) + causal-window 평활(δ_{ctx} 섞기).** prior 가 매 turn 상쇄되도록 설계돼
경계 판정이 $\delta_{eff} < \delta^*$ 단일 부등식으로 환원된다.

HP default

$\alpha=1 \cdot \text{lmda}=10 \cdot \text{eta}_{prev}=1.0 \cdot \text{use_rnn}=\text{True}$ ($\eta=1 \rightarrow$ 자동 skip) $\cdot \text{ctx_window}=3$ (m) $\cdot \text{ctx_decay}=0.7$ (ρ)
 $\cdot \text{ctx_blend_a}=0.5$ (a) $\cdot \text{sigma_delta_c}=0.0625 \cdot \text{var_likelihood_weight}=1.0 \cdot \text{delta_star}=0.5557$ (코드 place-
holder, v4.1.1 재calib=0.5594) $\cdot \text{restart_pe_threshold}=0.5$. 나머지 v3.3.9 상속.

결과 (공식 SuperDialseg metric, $\text{Score}=0.5F1+0.25(1-Pk)+0.25(1-WD)$)

벤치	method	Score	F1	Pk	WD
superseg	v3.3.9 @TIAGE- δ^*	0.460	0.449	0.468	0.589
superseg	v4.1.1 @TIAGE-cfg	0.463	0.432	0.471	0.541
dialseg711	v3.3.9 @TIAGE- δ^*	0.514	0.492	0.394	0.534
dialseg711	v4.1.1 @TIAGE-cfg	0.590	0.549	0.325	0.415
dialseg711	v4.1.1 @oracle- δ^*	0.629	0.560	0.285	0.319

causal-window 가 표준벤치 2개에서 v3.3.9 대비 일관 우위 (dialseg711 zero-shot Score +0.076). superseg 는 F1 trade (경계 덜 찍어 recall $\downarrow \leftrightarrow$ WD/Score $\uparrow$).

한계 / 검증 미해결

- δ^* 가 TIAGE-train 전이값 — superseg validation 재calibration 미완.
- 인접-cosine unsupervised 천장이 벤치별 상이 (superseg $\approx$ F1 0.46, dialseg711 $\approx$ 0.54).
- SOTA/문헌(0.55~0.65) 출처 · split · supervised · 인코더 미확정 $\rightarrow$ 외부 초과주장 금지. 인코더 = multi-qa-mpnet, 정합 ablation 미실행.
- oracle- δ^* 행은 test-tuned 상한, 외부주장 불가.

검증 노트 (2026-05-19, 코드 1:1 대조)

수식 자체 오류 없음. 정밀화 보정 3건:

1. L6 에 `var_likelihood_weight(default 1.0)` 계수 존재 (L368-372) — 식에 명시.
2. δ^* 코드 default 0.5557 = v3.3.9 prev-cos placeholder $\neq$ v4.1.1 causal 재calib 0.5594. 둘 구분 명시 (L146).
3. $c_{\{t-1\}}$ 가중치 인덱싱(reversed $\rightarrow s_{\{t-1\}}$ 이 ρ^0) 코드 재확인 (L413-414) — 식과 일치, 이상無.

prior 상쇄 환원($\delta_{\text{eff}} < \delta^*$) 대수 전개 재검증 완료. fresh baseline 의 prev_k-없을 때 `_l0()` fallback 경로도 코드와 일치 확인.